Implementierung von automatisierten Data-Masking-Verfahren als Schutzmaßnahme gegen Data Leakage bei der Nutzung von LLM-Schnittstellen

vorgelegt am 9. März 2026

Fakultät Wirtschaft und Gesundheit

Studiengang Wirtschaftsinformatik

Kurs WWI2025B

von

Florian Stahl

Matrikelnummer: [Matrikelnummer eintragen]

Betreuung in der Ausbildungsstätte:

Rober Bosch GmbH
Titel, Andreas Schurr
Funktion des Betreuers/der Betreuerin

Unterschrift

DHBW Stuttgart:

TitelDHBW Betreuer, Vorname und Nachname

Vertraulichkeitsvermerk: Der Inhalt dieser Arbeit darf weder als Ganzes noch in Auszügen Personen außerhalb des Prüfungs- und Evaluationsverfahrens zugänglich gemacht werden, sofern keine anders lautende Genehmigung des Dualen Partners vorliegt.

Inhaltsverzeichnis

Abkürzungsverzeichnis **III**

Tabellenverzeichnis **IV**

1 Einleitung **1**
1.1 Ausgangslage und Problemstellung 1
1.2 Zielsetzung und Aufbau der Arbeit 1

2 Theoretische Grundlagen und Problemanalyse **2**
2.1 Funktionsweise von Large Language Model (LLM)-Application Programming Interfaces (APIs) 2
2.2 Spezifische Risiken in der Informationstechnik (IT)-Infrastruktur 2

3 Technische Implementierung von Data-Masking **3**
3.1 Verfahren der Pseudonymisierung 3
3.1.1 Reguläre Ausdrücke 3
3.1.2 Named Entity Recognition 4
3.2 Das Utility-Privacy-Dilemma 4

4 Kritische Bewertung und Praxisrelevanz **5**
4.1 Governance-Aspekte: Einbindung in die IT-Infrastruktur 5
4.2 Compliance: Datenschutz-Grundverordnung (DSGVO) & Privacy by Design . . . 5

5 Fazit und Handlungsempfehlung **6**
5.1 Zusammenfassung der Ergebnisse 6
5.2 Handlungsempfehlung für die Praxis 6

Literaturverzeichnis **7**

Abkürzungsverzeichnis

API Application Programming Interface

DSGVO Datenschutz-Grundverordnung

GeschGehG Geschäftsgeheimnisgesetz

IT Informationstechnik

KI Künstliche Intelligenz

LLM Large Language Model

NER Named Entity Recognition

NIS-2 Sicherheit von Netz- und Informationssystemen

PII Personally Identifiable Information

Regex Reguläre Ausdrücke

REST Representational State Transfer

SLA Service Level Agreement

TLS Transport Layer Security

Tabellenverzeichnis

1 Vergleich der Maskierungstechniken 3

1 Einleitung

1.1 Ausgangslage und Problemstellung

In den letzten Jahren hat der Umgang mit Künstliche Intelligenz (KI) zu einer fundamentalen Veränderung in der IT-Landschaft geführt[1]. Gerade LLM-Modelle haben als transformative Technologie die Art und Weise, wie wir arbeiten, wie wir Informationen beschaffen und wie wir Probleme lösen, revolutioniert[2]. Besonders beliebt ist dabei die Integration von bestehenden LLM-APIs in eigene Softwarelösungen, da Unternehmen so schnell und kostengünstig von den Vorteilen der Künstliche Intelligenz (KI) profitieren können[3]. So werden bei Bosch z. B. LLM-APIs verwendet, um die IT-Infrastrukturen von Anwendungen zu analysieren und zu optimieren.

Das Problem ist dabei, dass die Integration von LLM-APIs in Softwarelösungen zwar starke Effizienzsteigerungen ermöglicht, gleichzeitig aber ein oft übersehenes Risiko mit sich bringt. Das Übertragen von kritischen Unternehmensdaten an Dritte korreliert unmittelbar mit unternehmenswirtschaftlichen Erfolgen. Wichtig dabei zu verstehen ist, dass die Verschlüsselung der Anfragen über Transport Layer Security (TLS) zwar die Integrität und Vertraulichkeit der Daten sichert, nicht aber den Zugriff des Anbieters selbst[4].

1.2 Zielsetzung und Aufbau der Arbeit

Um dieses Risiko zu minimieren, gilt es als Aufgabe dieser Arbeit, eine unsichtbare Schicht zwischen der Software und der API zu schaffen, mit der kritische Daten maskiert werden. So kann gewährleistet werden, dass die Daten dem API-Provider nicht ungeschützt zugänglich sind.

Die Frage, die diese Arbeit dabei beantworten soll, lautet dabei:

$$\textit{Inwiefern ermöglicht ein hybrider Data-Masking-Ansatz (Reguläre Ausdrücke (Regex) + Named Entity Recognition (NER)) einen effektiven Schutz sensibler IT-Infrastrukturdaten bei gleichzeitig hoher Antwortqualität von LLM-APIs?} \tag{1.1}$$

Um dieser nachzugehen, werden zunächst die theoretischen Grundlagen der LLM-API-Kommunikation und die damit verbundenen Risiken analysiert. Anschließend werden verschiedene Maskierungsansätze untersucht und unter anderem deren Einfluss und Effektivität auf die Antwortqualität untersucht[5]. Dabei schließt die Arbeit mit einer Bewertung der praktischen Einsetzbarkeit unter Berücksichtigung regulatorischer und governance-relevanter Aspekte.

[1] Naveed et al. 2023
[2] Al-Zubaidi et al. 2024
[3] Kucharavy et al. 2025
[4] Staab et al. 2025
[5] Zhang, Y., Chen, X. 2025

2 Theoretische Grundlagen und Problemanalyse

2.1 Funktionsweise von LLM-APIs

Die Kommunikation mit LLM-APIs erfolgt typischerweise über Representational State Transfer (REST)ful APIs, bei denen Anfragen an zentrale Server der API-Provider gesendet werden. Die Anfragen enthalten dabei den sogenannten Prompt sowie verschiedene Parameter wie Temperatur, Maximalzahl an Tokens, usw. Die Verbindung zum API-Provider wird typischerweise mit TLS verschlüsselt und verhindert somit Man-in-the-Middle-Angriffe und das Abhören von Dritten. Da jedoch unverschlüsselter Daten für die Verarbeitung der Modelle notwendig sind, kann der Zugriff des API-Providers auf die Informationen nicht verhindert werden[6]. Trotz Service Level Agreements (SLAs)s, welche die Sicherheit der Daten garantieren sollen, entsteht ein Vertrauensproblem zwischen API-Provider und API-Konsumierer, da die Kontrolle über die Daten bei externen Parteien liegt[7]. Dies stellt vor allem ein Problem dar, wenn die API-Provider unter einer anderen regulatorischen oder wettbewerbewerbswirksamen Umgebung als der API-Konsumierer stehen.

2.2 Spezifische Risiken in der IT-Infrastruktur

Um die Bedeutung der Daten zu verstehen, lohnt es sich diese zu kategorisieren. Es wird unterschieden zwischen personenbezogenen Daten (Personally Identifiable Information (PII)) einerseits und geschäftskritischen Infrastrukturdaten andererseits. Personenbezogene Daten umfassen dabei alle Daten, die eine natürliche Person eindeutig identifizieren können. Das können zum Beispiel Namen, E-Mail-Adressen, Telefonnummern, etc. sein. Bei diesen greift die DSGVO, weswegen eine unachtsame Verwendung der Daten zu erheblichen Geldbußen und Reputationsschäden führen kann[8]. Die Kategorie der geschäftskritischen Infrastrukturdaten umfasst hingegen alle Daten, die für die Betriebsführung relevant sind. Dazu zählen in diesem Fall unter anderem IP-Adressen und Netzwerksegmentierungen, Servernamen und deren Betriebssystemversionen, etc. Im Gegensatz zu personenbezogenen Daten existieren dabei das Geschäftsgeheimnisgesetz (GeschGehG) oder die Sicherheit von Netz- und Informationssystemen (NIS-2)-Richtlinie, welche die Offenlegung dieser Daten einschränken[9]. Das Risiko liegt stattdessen darin, dass die Offenlegung dieser die Sicherheitsinfrastruktur des Unternehmens massiv kompromittieren kann[10].

[6] Staab et al. 2025
[7] Tantoush et al. 2025
[8] Chen, J., Zhang, H. et al. 2024
[9] Parliament 2025
[10] Deng et al. 2024

3 Technische Implementierung von Data-Masking

3.1 Verfahren der Pseudonymisierung

Vor der detaillierten Betrachtung der einzelnen Verfahren bietet sich ein systematischer Vergleich der beiden zentralen Maskierungstechniken an:

Tab. 1: Vergleich der Maskierungstechniken

Kriterium	**Regex**	**NER**
Erkennungsgenauigkeit	Hoch für strukturierte Daten (IP-Adressen, E-Mails)	Hoch für unstrukturierte, kontextuelle Daten
Latenz	Sehr gering (Millisekunden)	Höher (abhängig von Modellgröße)
Komplexität	Niedrig (regelbasiert)	Hoch (KI-basiert, erfordert Training)
Wartbarkeit	Manuelle Regelpflege erforderlich	Kontinuierliches Fine-Tuning nötig
Einsatzgebiet	Formale, standardisierte Datenformate	Freitext, variable Formulierungen
Ressourcenbedarf	Minimal (CPU-basiert)	Hoch (GPU für Transformer-Modelle)

3.1.1 Reguläre Ausdrücke

Regex gilt als verbreitetste Methode zur Identifikation von Mustern in Texten. Es verwendet vordefinierte Zeichenketten, um spezifische Textmuster mit hoher Präzision in einer Zeichenkette zu finden. Im Kontext von IT-Infrastrukturen können so z. B. IP-Adressen identifiziert werden und für die weitere Verarbeitung mit pseudonymisierten Werten maskiert werden[11].

Der große Vorteil von Regex ist dabei die schnelle und ressourcenschonende Verarbeitung der Daten, da moderne Regex-Engines hochoptimiert für String-Verarbeitungsalgorithmen sind. Dabei können auch Datenbank-Verbindungsstrings, welche typischerweise Schlüsselwörter wie ßerver", "databaseöder "passwordënthalten, zuverlässig erkannt und nachfolgende Informationen maskiert werden. Die Implementierung einer solchen Lösung erfolgt typischerweise durch die Verwendung von Regex-Bibliotheken oder spezialisierten Frameworks.

Die Limitation von Regex liegt jedoch darin, dass es sich um eine rein regelbasierte Methode handelt. So können z. B. Servernamen, welche einer bestimmten Namenskonvention folgen (z. B. "prod-db-server-01"), zuverlässig erkannt und maskiert werden. Werden die Servernamen jedoch willkürlich gewählt (z. B. "der Hauptdatenbankserver"), kann Regex diese nicht mehr erkennen, da in diesem Fall semantische Zusammenhänge verwendet werden müssen und syntaktische Mustererkennung nicht ausreicht[12]. Gleichzeitig besteht die Gefahr des Undermaskings: Neue oder unbekannte Namenskonventionen oder Datenformate werden nicht in die Regex-Regeln aufgenommen und somit nicht erkannt, bzw. die Gefahr des Overmaskings, bei der zu viele Daten maskiert werden und folglich die Antwortqualität der LLM-API sinkt.

[11] Tobiloba 2025
[12] Srivastava et al. 2024

3.1.2 Named Entity Recognition

Im Gegensatz zu Regex adressiert NER das Problem der Datenmaskierung mithilfe von semantischer Klassifikation[13]. Dabei wird ein kontextuelles Sprachverständnis genutzt, um die Bedeutung von Wörtern im umgebenden Text zu erfassen und somit auch Entitäten zu erkennen, welche nicht explizit in Regeln definiert sind. NER "denkt mitünd ein Servername wird nicht erkannt, weil er aussieht wie ein Servername, sondern weil der Satzbau (z. B. „...verbindet sich mit dem Host Alpha-Prime...“) auf eine IT-Entität hindeutet.

Der Nachteil von NER zeigt sich jedoch in der Komplexität und den Ressourcen, welche für das Training und den Betrieb benötigt werden. So müssen die Modelle aufwendig trainiert und gewartet werden, was zeit- und kostenintensiv sein kann. Aus diesem Grund lohnt sich der Einsatz von NER nur, wenn eine hohe Genauigkeit bei der Erkennung von Entitäten erforderlich ist und die Ressourcen für das Training vorhanden sind.

Als Alternative bietet sich ein hybrider Kaskaden-Ansatz an[14]. Dabei wird die Anfrage zuerst mit minimaler Latenz durch ein Regex-basiertes Modell geschickt. Alles, was harte Muster enthält, wird erkannt und mit pseudonymisierten Namenskonventionen ersetzt. Der verbleibende Text wird daraufhin an das NER-basierte Sicherheitsnetz geschickt, welches verbleibende Informationen erkennt und maskiert. Dieses System stellt dabei nicht nur eine hohe Effizienz bereit, sondern auch eine erhöhte Zuverlässigkeit, da sich die beiden Modelle ergänzen[15]. In einem abschließenden De-Maskierungsschritt innerhalb der Middleware werden die Platzhalter (z. B. [IP_1]) durch die im gemeinsamen Token-Speicher gespeicherten ursprünglichen Werte ersetzt[16]. Da dieser Speicher das Unternehmen nie verlässt, bleibt die Souveränität über die Rohdaten gewahrt, während der Nutzer eine kontextualisierte Antwort erhält.

3.2 Das Utility-Privacy-Dilemma

Die zentrale Herausforderung bei einer erfolgreichen Datenmaskierung liegt in der Balance zwischen dem Schutz sensibler Daten (Privacy) und der gleichzeitigen Erhaltung der Nützlichkeit der Daten (Utility) für die LLM-API. In der aktuellen Forschung wird dies als Privacy-Utility-Tradeoff definiert[17]. Maximale Antwortqualität für die LLM-API bedeutet maximale Datenmenge, was wiederum maximale Risiken für die Privatsphäre bedeutet. Umgekehrt führt eine maximale Datenminimierung oft zu einer signifikanten Einbuße bei der Antwortqualität der LLM-API[18]. So kann die LLM-API zum Beispiel nicht mehr die logischen Zusammenhänge der IT-Infrastruktur verstehen und fehlerhafte Antworten generieren.

[13] Srivastava et al. 2024
[14] Naseer et al. 2025
[15] Naseer et al. 2025
[16] Vignati et al. 2024
[17] Wang et al. 2025
[18] Wang et al. 2025

4 Kritische Bewertung und Praxisrelevanz

4.1 Governance-Aspekte: Einbindung in die IT-Infrastruktur

Wichtig für eine erfolgreiche Einbindung eines Maskierungsalgorithmus ist die Vermeidung von sogenannten Schatten-KIs. Darunter versteht man LLM-Systeme, welche nicht von einer IT-Abteilung bereitgestellt wurden und somit auch keinen Maskierungsalgorithmus verwenden[19]. Da Mitarbeiter bei fehlenden oder unperformanten Systemen oft stattdessen auf nicht geschützte LLM-Systeme zurückgreifen, ist es wichtig, interne LLM-Systeme bereitzustellen, die nicht nur aktiv beworben werden, sondern auch auf dem aktuellen Stand der Technik sind.

Der hybride Ansatz ist hierbei entscheidend, da er die hohe Präzision von NER mit der minimalen Latenz von Regex kombiniert. Nur eine performante Lösung, die den Arbeitsfluss nicht durch lange Wartezeiten unterbricht, kann die Akzeptanz der Mitarbeiter sicherstellen und somit den Rückzug in ungeschützte Schatten-KI-Systeme effektiv verhindern[20].

Zudem sollte man abwägen, ob ein lokales LLM-Modell (on-premise), zum Beispiel auf eigenen Servern, günstiger und effizienter wäre, als ein pseudonymisierendes externes LLM-Modell, welches über eine API angesprochen wird[21]. Dieses Modell würde keinen Maskierungsalgorithmus verwenden, was die Antwortqualität und Latenz verbessern würde.

Zuletzt ist es auch wichtig, dass Mitarbeiter über „Residual Risks“ (Restrisiken) geschult werden, denn kein Maskierungsalgorithmus kann die absolute Sicherheit der Daten garantieren[22]. Deshalb ist es wichtig, nicht nur die technische Implementierung, sondern auch die organisatorischen Maßnahmen zu prüfen.

[Image of cloud vs on-premise LLM infrastructure comparison]

4.2 Compliance: DSGVO & Privacy by Design

Auch die DSGVO nennt explizit die datenschutzfreundliche Voreinstellung und den Datenschutz durch Technik (Privacy by Design) als Grundsätze der Datenverarbeitung. In Artikel 25 der DSGVO heißt es dazu:

> Der Verantwortliche trifft geeignete technische und organisatorische Maßnahmen, um sicherzustellen, dass grundsätzlich nur Datenverarbeitungen vorgenommen werden, die für den jeweiligen Zweck erforderlich sind.

[19] Mansner 2025
[20] Naseer et al. 2025
[21] Authors 2025
[22] Staab et al. 2025

Gleichzeitig wird in Artikel 32 der DSGVO sogar explizit die Pseudonymisierung als Maßnahme genannt, welche zur Erfüllung dieser Pflicht beitragen können. Zusätzlich wird in dem neuen EU AI Act die Verwendung von KI-Systemen zur Analyse von biometrischen Daten oder zur Erkennung von Emotionen stark eingeschränkt, was zeigt, dass die Bedeutung von Datenschutz und Datensicherheit in der EU zunimmt[23].

5 Fazit und Handlungsempfehlung

5.1 Zusammenfassung der Ergebnisse

Um die Kontrolle über interne Daten zu behalten und gleichzeitig den steigenden Compliance-Anforderungen gerecht zu werden, ist eine technische Pseudonymisierung bei der Nutzung externer LLM-APIs für Unternehmen heute unerlässlich[24]. Mit einem hybriden Ansatz, der die deterministische Präzision von Regex für strukturierte Daten mit der semantischen Flexibilität von NER für unstrukturierte Kontexte kombiniert, können die Vorteile beider Ansätze genutzt werden[25].Trotzdem sollte beachtet werden, dass eine vollständige Pseudonymisierung oft schwierig ist und die Qualität der Ergebnisse beeinträchtigen kann. Deshalb sind kontinuierliche Optimierungen notwendig, um ein zu striktes Maskierungsverfahren zu vermeiden[26].

5.2 Handlungsempfehlung für die Praxis

Um ein solches Modell in der Praxis umzusetzen, gibt es verschiedene Anbieter, welche Open-Source-Lösungen anbieten. Zu nennen sind hierbei insbesondere Microsoft Presidio, Skyflow oder Privacera[27]. Dabei kann zum Beispiel ein Stufenmodell eingesetzt werden, welches eine von Grund auf strikte Maskierung sukzessiv je nach Anwendungsfall lockert. Wichtig dabei sind vor allem regelmäßige Audits der Maskierungs-Logs, um Fehlklassifizierungen der Modelle zu finden[28].

[23] Parliament 2025
[24] Staab et al. 2025
[25] Naseer et al. 2025
[26] Wang et al. 2025
[27] Vignati et al. 2024
[28] Zhang, Y., Chen, X. 2025

Literaturverzeichnis

Authors, Anonymized (2025): A Cost-Benefit Analysis of On-Premise Large Language Model Deployment: Breaking Even with Commercial LLM Services. In: *arXiv preprint arXiv:2509.18101*. URL: https://arxiv.org/abs/2509.18101.

Chen, J.; Zhang, H. et al. (2024): Understanding PII Leakage in Large Language Models: A Systematic Survey. In: *Proceedings of the 34th International Joint Conference on Artificial Intelligence (IJCAI-25)*. URL: https://www.ijcai.org/proceedings/2025/1156.pdf.

Deng, J. et al. (2024): Large Language Models in Cybersecurity: A Survey of Applications, Vulnerabilities, and Defense Techniques. In: *MDPI Cybersecurity* 6.9, S. 216. DOI: 10.3390/a18080499.

Kucharavy, Andrei et al. (2025): The Impact of LLM-Assistants on Software Developer Productivity: A Systematic Literature Review. In: *arXiv preprint arXiv:2507.03156*. URL: https://arxiv.org/abs/2507.03156.

Mansner, Veera (2025): Shadow AI and Organizational Governance: A Case Study of Technology Use Beyond IT Oversight. Master's Thesis. Haaga-Helia University of Applied Sciences. URL: https://www.theseus.fi/handle/10024/899783.

Naseer, A. et al. (2025): RECAP: An Evaluation Study of Hybrid Methods for Multilingual PII Detection. In: *arXiv preprint arXiv:2510.07551*. URL: https://arxiv.org/abs/2510.07551.

Naveed, Humza; Khan, Asad Ullah; Qiu, Shi; Saqib, Muhammad; Anwar, Saeed; Usman, Muhammad; Akhtar, Naveed; Barnes, Nick; Mian, Ajmal (2023): A Comprehensive Overview of Large Language Models. In: *arXiv preprint arXiv:2307.06435*. URL: https://arxiv.org/abs/2307.06435.

Parliament, European (2025): Interplay between the AI Act and the EU digital legislative framework (NIS2, GDPR, and Cyber Resilience Act). Techn. Ber. European Parliamentary Research Service (EPRS). URL: https://www.europarl.europa.eu/RegData/etudes/STUD/2025/778575/ECTI_STU(2025)778575_EN.pdf.

Srivastava, A. et al. (2024): Recent Advances in Named Entity Recognition: A Comprehensive Survey and Comparative Study. In: *arXiv preprint arXiv:2401.10825*. URL: https://arxiv.org/abs/2401.10825.

Staab, Robin; Vero, Mark; Balunovic, Mislav; Vechev, Martin (2025): SoK: The Privacy Paradox of Large Language Models: Advancements, Privacy Risks, and Mitigation. In: *arXiv preprint arXiv:2506.12699*. URL: https://arxiv.org/abs/2506.12699.

Tantoush, M. et al. (2025): Digital Sovereignty and Cloud Dependencies: A Reference Architecture for AI-Enabled Systems. In: *arXiv preprint arXiv:2602.05486*. URL: https://arxiv.org/abs/2602.05486.

Tobiloba, Oluwadamilare I. (2025): Enhancing OCR Accuracy with Regex Patterns: Limitations, Strengths, and Comparative Analysis. In: *ResearchGate preprint*. URL: https://www.researchgate.net/publication/389374337.

Vignati, A. et al. (2024): Towards a Middleware for Large Language Models. In: *arXiv preprint arXiv:2411.14513*. URL: https://arxiv.org/abs/2411.14513.

Wang, H. et al. (2025): Revisiting Privacy, Utility, and Efficiency Trade-offs when Fine-Tuning Large Language Models. In: *arXiv preprint arXiv:2502.13313*. URL: https://arxiv.org/abs/2502.13313.

Zhang, Y.; Chen, X. (2025): A Survey of Privacy Preservation Techniques for Large Language Models. In: *Proceedings of the IEEE International Conference on Edge Computing (EDGE)*. DOI: 10.1109/EDGE2025.00012.

Al-Zubaidi, Naser et al. (2024): A Research Landscape of Agentic AI and Large Language Models: Applications, Challenges and Future Directions. In: *Algorithms* 18.8, S. 499. DOI: 10.3390/a18080499.

Erklärung zur Verwendung generativer KI-Systeme

Bei der Erstellung der eingereichten Arbeit habe ich auf künstlicher Intelligenz (KI) basierte Systeme benutzt:

☒ ja

☐ nein[29]

Falls ja: Die nachfolgend aufgeführten auf künstlicher Intelligenz (KI) basierten Systeme habe ich bei der Erstellung der eingereichten Arbeit benutzt:

1.

2.

3. ...

Ich erkläre, dass ich

- mich aktiv über die Leistungsfähigkeit und Beschränkungen der oben genannten KI-Systeme informiert habe,[30]
- die aus den oben angegebenen KI-Systemen direkt oder sinngemäß übernommenen Passagen gekennzeichnet habe,
- überprüft habe, dass die mithilfe der oben genannten KI-Systeme generierten und von mir übernommenen Inhalte faktisch richtig sind,
- mir bewusst bin, dass ich als Autorin bzw. Autor dieser Arbeit die Verantwortung für die in ihr gemachten Angaben und Aussagen trage.

Die oben genannten KI-Systeme habe ich wie im Folgenden dargestellt eingesetzt:

Arbeitsschritt in der wissenschaftlichen Arbeit	**Eingesetzte(s) KI-System(e)**	**Beschreibung der Verwendungsweise**

[29] Die Erklärung ist in jedem Fall zu unterzeichnen, auch wenn Sie keine KI-Systeme genutzt haben und Ihr Kreuz bei „nein“ gesetzt haben.

[30] U.a. gilt es hierbei zu beachten, dass an KI weitergegebene Inhalte ggf. als Trainingsdaten genutzt und wiederverwendet werden. Dies ist insb. für betriebliche Aspekte als kritisch einzustufen.

(Ort, Datum) (Unterschrift)

Erklärung

Ich versichere hiermit, dass ich die vorliegende Arbeit mit dem Thema: *Implementierung von automatisierten Data-Masking-Verfahren als Schutzmaßnahme gegen Data Leakage bei der Nutzung von LLM-Schnittstellen* selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe. Ich versichere zudem, dass die eingereichte elektronische Fassung mit der gedruckten Fassung übereinstimmt.

(Ort, Datum) (Unterschrift)